

דו"ח מסכם – ניסוי בבעיית העצירה האופטימלית – אינטראקציית אדם סוכן

מגישים: עומר דימרי (315564203) ומתן מלכה (308046937).

קישור ל-GitHub: [Stop-Problem Repository](#)

הערה: לכל בעיה בהרצת הקוד ניתן לפנות למתן מלכה (053-6292669, matanmkl@gmail.com).

נושא העבודה: ניתוח ולמידה של אינטראקציה אנושית בבעיית העצירה המוחלטת וחזיון התנהגות ע"ב דפוסים קודמים.

את הצגת העבודה נעשה ע"פ הפרקים הבאים:

1. תיאור הנושא, הבעיה והניסוי.
2. תיאור מבני הנתונים בהם השתמשנו + חבילת הקוד.
3. הסבר על הרצת הקוד + הצגת תוצאות.
4. תוצאות הניסוי.

1. תיאור הנושא, הבעיה והניסוי:

במתמטיקה, התיאוריה של **עצירה אופטימלית** או עצירה מוקדמת עוסק בבעיה בבחירת זמן לביצוע פעולה מסוימת, על מנת למקסם תגמול צפוי או למזער עלות צפויה. ניתן למצוא בעיות עצירה אופטימליות בתחומי סטטיסטיקה, כלכלה ו- מימון מתמטי ותחומים נוספים רבים. דוגמה מרכזית לבעיית עצירה מיטבית היא **בעיית המזכירה**. כדי לפשט את הבעיה לנושא יותר "ארצי" ועל מנת למקד את הדיון התיאורטי נמקד אותו סביב בעיית המזכירה דרכה ניתן להשליך אודות בעיות דומות.

א. תיאור הבעיה: בעיית המזכירה היא סוגיה מתמטית בתורת ההסתברות שמתארת מצב שבו צריך לבחור בין מספר אפשרויות שמתגלות זו אחר זו. לאחר שאפשרות מסוימת מתגלה, אפשר לבחור בה או לוותר עליה. אם בוחרים באפשרות, לא ניתן להחליף אותה באפשרות אחרת שמתגלה מאוחר יותר. אם מוותרים על האפשרות, לא ניתן לחזור אליה מאוחר יותר. סיפור שנועד להמחיש בעיה זו, ושעל שמו היא נקראת, מספר על מעסיק שמחפש מזכירה ומפרסם מודעה בעיתון שעליה עונות N מועמדות שמגיעות למשרדו. ברצונו של המעסיק לשכור את המועמדת הטובה ביותר מבין אלו שהופיעו. את המועמדות הוא מראיין זו אחר זו בסדר אקראי, ואחרי כל ראיון, עליו להחליט אם להציע למועמדת הנוכחית את המשרה או לעבור למועמדת הבאה. בעת שהוא מחליט, הוא יכול לדרג את המועמדות שראה עד עתה, אך אין ביכולתו להשוות אותן למועמדות שטרם ראיין. אם יחליט המעסיק לא להציע למועמדת הנוכחית את המשרה, היא תיעלב ולא תסכים לקבל את המשרה אם לאחר שראיין עוד

מועמדות יחזור ויציע לה את המשרה. לכן, מיד אחרי ראיון שקיים עם כל מועמדת, חייב המעסיק להתחייב להעסיקה או לוותר על שירותיה. תנאי הבעיה קובעים שאם לא נשכרה אף מועמדת לפני המועמדת האחרונה, המעביד יהיה חייב לשכור אותה. השאלה שהבעיה עוסקת בה היא כיצד אפשר להגדיל את הסיכוי לשכור את המועמדת הטובה ביותר, ומה ההסתברות שהמועמדת הטובה ביותר תיבחר תחת האסטרטגיה האופטימלית.

זוהי בעיה שפתרונה נלמד בקורסי המבוא לאלגוריתמים לרוב והיא מוכרת לסטודנטים רבים. אולם הפתרון שמוצג לבעיה הינו תיאורטי ואינו ישים בעולם האמיתי, נציג את הפתרון האופטימלי לבעיה ולאח"כ מכן נדון בקצרה מדוע הוא אינו ישים.

ב. הפתרון לבעיה: הפתרון האופטימלי לבעיה מתאפיין בכך שעבור ערכים גדולים של N , ההסתברות

לבחור במועמדת הטובה ביותר היא קצת יותר משליש, או ליתר דיוק היא קרובה ל- $\frac{1}{e}$. תוצאה זו

נחשבת כמפתיעה, מפני שממבט ראשון קשה להאמין שמתוך 100 מועמדות, ההסתברות שנצליח לבחור את המועמדת הטובה ביותר תהיה כל כך גבוהה, בפרט שבחירה אקראית (למשל, אם תמיד נשכור את המועמדת החמישית שנראיין, תהיה אשר תהיה) תבחר במועמדת הטובה ביותר רק פעם אחת למאה.

כאמור, מספר המועמדות עליו כדאי לפסוח תלוי ב- N . אבל אפשר להראות שעבור N גדול דיו, מספר

המועמדות שעליו כדאי לוותר שואף ל- $\frac{N}{e}$. במילים אחרות, עבור מספר גדול של מועמדות, האסטרטגיה

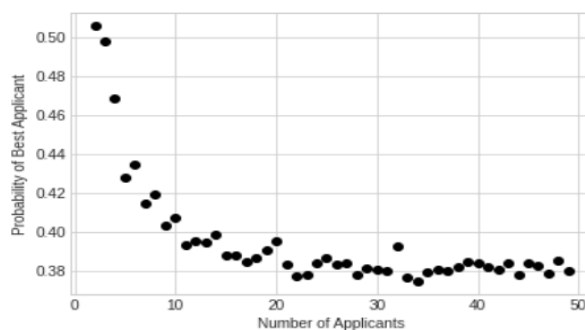
האופטימלית היא לפסוח על אחוז קבוע מהמועמדות (בערך

37%) ואז לבחור את המועמדת הראשונה שעדיפה על

הטובה מבין המועמדות הראשונות הללו. כפי שכבר הוזכר

לעיל, תחת אסטרטגיה זו, ההסתברות שנבחר נכון היא

בערך $\frac{1}{e}$ קירוב שיהיה יותר מדויק ככל ש- N יותר גדול.



Number of Applicants	Take the Best Applicant After	Chance of Getting the Best
3	1 (33.33%)	50%
4	1 (25%)	45.83%
5	2 (40%)	43.33%
6	2 (33.33%)	42.78%
7	2 (28.57%)	41.43%
8	3 (37.5%)	40.98%
9	3 (33.33%)	40.59%
10	3 (30%)	39.87%
20	7 (35%)	38.42%
30	11 (36.67%)	37.86%
40	15 (37.5%)	37.57%
50	18 (36%)	37.43%
100	37 (37%)	37.10%
1000	369 (36.9%)	36.81%

ג. בעייתיות הפתרון: ברור שגם אילו בעיית המזכירה או כל מידול אחר שלה לא היה תיאורטי בלבד הפתרון המוצע הוא בפרט תיאורטי לחלוטין. הרי בחיים האמיתיים אין לנו ידע על כמות המזכירות שיעברו אצלנו ראיונות ולכן האפשרות להגיע לתוחלת האופטימלית המובטחת היא תיאורטית בלבד.

ד. הניסוי: הניסוי שלנו בא לבחון את ההתמודדות של אנשים עם הסוגייה הזאת ולנסות לבדוק האם קיימת דרך לנתח את אופן קבלת ההחלטות שלהם כך שניתן יהיה לצפות אותן מראש. כלומר ננסה ללמוד את האסטרטגיה החישובית של השחקן גם אם הוא אינו מודע לכך שהוא משתמש בה. למידת האסטרטגיה תתבצע בעזרת וקטורי מידע שונים שיוזנו למערכת:

(1) מטה-דטה:

המודל ישתמש במידע אודות השחקן:

(א) גיל

(ב) מגדר

(2) ערכי המשחק:

המודל ייקח בחשבון את נתוני המחשק הספציפי:

(א) כלל הערכים המופיעים

(ב) הערך האופטימלי ואינדקס הופעתו

(ג) הערך הגרוע ביותר ואינדקס הופעתו

(ד) הערכים האמצעיים ואינדקס הופעתם

(3) בחירות המשתמש:

(א) ערך בבחר

(ב) אינדקס בבחר

(ג) זמן מחשבה עבור כל ערך

(ד) זמן מחשבה כולל

במהלך הניסוי אספנו מידע ראשוני משני מקורות עיקריים:

(1) לקיחת מידע מניסוי עליו ביססנו את הניסוי. מניסוי זה לקחנו כ – 178 דגימות, אך דגימות אלו לא קיים המטה-דאטא של כל שחקן.

2) אפליקציית רשת אשר הקמנו במיוחד לכבוד הפרוייקט. באתר אפשר לשחק את בעיית העצירה עם אותם סבבים אשר השתמשו בניסוי המקורי. מהאתר אספנו כ- 200 דגימות, דגימות אלו כוללות את המטה-דאטא של כל שחקן.

בסופו של דבר קיבלנו שתי צורות למידע- מידע שלם אשר התקבל מהאתר ומידע חלקי (חסר מטה-דאטא וללא זמני מחשבה מדויקים) מהניסוי המקורי. השוני הזה יכול להועיל לנו אף יותר ולהוסיף תת ניסוי בתוך המערכת – מה היא מידת השפעתו של המטה-דטה על המערכת?

2. תיאור מבני הנתונים בהם השתמשנו:

- א) רצינו ליצור מערכת איסוף נתונים שתהיה קלה ונגישה למשתמשים רבים ובנוסף להכניס לניסוי מעין תחושה אינטראקטיבית של משחק. לכן החלטנו ליצור [אפליקציה אינטרנטית](#). כתבנו את האפליקציה באמצעות Django Web Framework, חבילת פייתון נפוצה לבניית אפליקציות רשת ופרסנו אותה לרשת דרך שירות האחסון של Heroku. הצלחנו להגיע להמון דאטה בעזרת הנגישות של האפליקציה דבר שעזר לנו לבצע את הניסוי ולהגיע לתוצאות שהגענו אליהם.
- ב) את מבני הנתונים בהם עשינו שימוש ניתן לראות תחת models בתוך חבילת stop_problem, בעזרת המודלים הללו הגדרנו את הטבלאות במסד הנתונים שלנו ולאחר מכן המרנו את הנתונים ששמרנו למטריצה ב-numpy שבה שמרנו את כל הערכים הרלוונטיים ללמידה של המודל.
- ג) את המודל בנינו בעזרת חבילת pytorch הידועה בתחום ה-ML, יצרנו אובייקט Dataset של המידע אותו רצינו ללמוד וחילקנו אותו לסט אימון וסט ולידיציה. בנינו מודל DNN בעל 4 שכבות ראשוניות ועוד שכבה חמישית שמפוצלת על בסיס משתנה באתחול המודל. השכבה המפוצלת היא בעצם ההחלטה של המודל לגבי האינדקס אותו צפוי המשתמש לבחור על פי בחירותיו הקודמות.

```
"""
returns a numpy array representing the data for a single player with shape (11,51).
data representation as follows:
[0]: Player meta-info:
    [0] - age
    [1-4] - gender as one-hot encoded vector
    [4-50] - padding with -1 as null value
[1-10]:
    [0-26]: Sequence related data:
        [0-19] - sequence values
        [20] - sequence optimal value
        [21] - sequence optimal index
        [22] - sequence worst value
        [23] - sequence worst index
        [24] - sequence median value
        [25-26] - sequence median indices
    [27-50]: Player answer data:
        [27]: chosen value
        [28]: chosen index
        [29]: total time in seconds
        [30-50]: time spent decoding weather to pick a value or pass (padded with -1 after 30 + <chosen index>)
"""
```

3. הסבר על הרצת הקוד + הצגת תוצאות:

תחילת הקוד הינו יצירת הדטה-סט מקבצי ג'ייסון אשר מכילים את המידע שאספנו. בזכור אספנו שני סוגי דטה כאשר הסוג הראשון מגיע מהאתר ומכיל מטה-דטה באופן מלא, מנגד הסוג השני מגיע מהניסוי המקורי ומכיל מטה דטה באופן חלקי. המטה דקה החלקי מחסיר את גילו ומגדרו של השחקן ואף מחסיר את הזמן האמיתי שלקח לשחקן לפעול עבור כל ערך (קיים הזמן הכולל ופיצלו באופן יוניפרמי לזמנים ספציפיים תחת האינדקסים).

4. תוצאות הניסוי:

• מטה-דטה מלא:

אחוז הדיוק על סט האימון עומד על כ-93.9% בעוד שאחוז הדיוק על סט הבדיקה עומד על כ-45.16%.

• מטה-דטה חלקי:

אחוז הדיוק על סט האימון עומד כל כ-90.7% בעוד שאחוז הדיוק על סט הבדיקה עומד על כ-25.4%.

על פי תוצאות המדגם הגענו על שתי הממצאים חשובים:

1. הצלחנו להגיע ליותר מ-45% דיוק, מבחינתנו זוהי הצלחה מהדהדת אשר מאפשרת לנו להגדיר את הניסוי כמוצלח. הראנו היתכנות ללמידה של אסטרטגיות חשיבה בעלות רגש עבור בני אדם! חשוב להבין שאחוזי הדיוק הללו על אף שעלולים להישמע נמוכים גבוהים מאוד. מתוך 20 אינדקסים אפשריים המודל הצליח לפגוע במדויק באינדקס הנבחר הנכון ב-45% מהמקרים, לשם השוואה מודל רנדומלי לחלוטין יגיע לכדי 5% דיוק בתוחלת, ועל כן מדובר בשיפור של פי 9 מניחוש אקראי.
2. בנוסף ברור שבניסוי בסדר גודל קטן שכזה הוא רק לשם POC של הנושא, ז"א יש כאן עדות חזקה לכך שנושא הבנה, למידה וחיזוי של אסטרטגיות של בני אדם בביצוע בחירות במצבים דומים הוא למיד PAC, מכאן ניתן לפתח את הנושא לתחומים מורכבים אף יותר.
3. בתת הניסוי שלנו אפשר לראות את הפרשי ההצלחה במצבי מטה דטה שונים. בכך אפשר להגיד כי קבלת המטה-דטה משפיעה באופן ישיר על המודל, המודל מצליח להבחין בסממנים מהותיים בשחקן עוד לפני שהתחיל לשחק!